

Анализ рынка недвижимости



Данные

author - автор объявления
author_type - тип автора
url - ссылка на объявление
floor - этаж
floors_count - общее количество этажей
rooms_count - количество комнат
total_meters - общая площадь
price_per_month - стоимость в месяц
commissions - комиссия, взимаемая при заселении
district - район
street - улица
house_number - номер дома
underground - метро

Заданы:

location - Москва
deal_type - rent
accommodation_type - flat

Пропуски

```
# Посмотрим количество пропусков  
df.isna().sum()
```

author	2
author_type	2
url	0
location	0
deal_type	0
accommodation_type	0
floor	0
floors_count	0
rooms_count	0
total_meters	0
price_per_month	0
commissions	0
district	458
street	83
house_number	15
underground	61
residential_complex	5585
dtype:	int64

```
# Удалим столбец residential_complex, location, deal_type, accommodation_type (последние 3 не несут никакой важной информации)
df.drop(['residential_complex', 'location', 'deal_type', 'accommodation_type'], axis=1, inplace=True)
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 5585 entries, 0 to 5584
```

```
Data columns (total 13 columns):
```

#	Column	Non-Null Count	Dtype
0	author	5583 non-null	object
1	author_type	5583 non-null	object
2	url	5585 non-null	object
3	floor	5585 non-null	int64
4	floors_count	5585 non-null	int64
5	rooms_count	5585 non-null	int64
6	total_meters	5585 non-null	float64
7	price_per_month	5585 non-null	int64
8	commissions	5585 non-null	int64
9	district	5127 non-null	object
10	street	5502 non-null	object
11	house_number	5570 non-null	object
12	underground	5524 non-null	object

```
dtypes: float64(1), int64(5), object(7)
```



Описательные статистики

```
df.describe()
```

	floor	floors_count	rooms_count	total_meters	price_per_month	commissions
count	5585.000000	5585.000000	5585.000000	5585.000000	5.585000e+03	5585.0
mean	8.606804	16.376007	2.343599	78.871606	1.816263e+06	0.0
std	8.596917	12.974562	1.075219	54.231389	1.238401e+08	0.0
min	1.000000	2.000000	-1.000000	12.000000	1.500000e+04	0.0
25%	3.000000	9.000000	1.000000	40.000000	5.000000e+04	0.0
50%	6.000000	14.000000	2.000000	59.000000	7.000000e+04	0.0
75%	11.000000	19.000000	3.000000	100.000000	2.000000e+05	0.0
max	82.000000	95.000000	5.000000	370.000000	9.255074e+09	0.0

```
# Обратили внимание, что по переменной rooms_count минимальное значение равно -1, а по переменной commissions нули
df.drop('commissions', axis=1, inplace=True)
# Выяснили, что по этой переменной есть пропуски, которые обозначаются -1
df.loc[df['rooms_count'] == -1]
```

	author	author_type	url	floor	floors_count	rooms_count	total_meters	price_per_month	district	street
1544	Руслан Османов	realtor	https://www.cian.ru/rent/flat/302241063/	3	5	-1	25.5	50000	Хамовники	Зубовская

```
# Так как лишь одно наблюдение содержит пропуск, мы его удалим
df = df.drop([1544])
df.loc[df['rooms_count'] == -1].shape[0] # убедились, что удаление прошло успешно
```

0

Создание новой переменной

```
df['price_per_m2'] = df['price_per_month'] / df['total_meters']
```

Создали новую переменную - цена за квадратный метр



Значения категориальной переменной

```
df['author_type'].value_counts()
```

```
author_type
real_estate_agent    3639
realtor              1661
homeowner            190
unknown              76
official_representative 16
Name: count, dtype: int64
```

real_estate_agent - агентство недвижимости
homeowner - собственник
realtor - риелтор
official_representative - укр. оф.представитель
unknown - без указанного типа

```
df['author'].loc[df['author_type'] == 'real_estate_agent'].value_counts().head(6)
```

```
author
Capital Mars    521
MY HOME        223
Intermark Real Estate 128
ПИК-Аренда     121
Apple Real Estate 118
The IMPERIUM    100
Name: count, dtype: int64
```

Создание дамми-переменных

Переменная = 1, если предложение квартиры от агентства недвижимости

```
df['real_estate_agent_dummy'] = 0  
df['real_estate_agent_dummy'].loc[df['author_type'] == 'real_estate_agent'] = 1
```


Переменная = 1, если предложение квартиры от риелтора

```
df['realtor_dummy'] = 0  
df['realtor_dummy'].loc[df['author_type'] == 'realtor'] = 1
```




Переменная = 1, если предложение квартиры от собственника

```
df['homeowner_dummy'] = 0  
df['homeowner_dummy'].loc[df['author_type'] == 'homeowner'] = 1
```

Тепловая карта






Гистограммы






Основные идеи:

- Большая часть квартир в объявлениях находится на 1-10 этажах, их размер до 50 м²;
- В основном этажность домов - до 20 этажей;
- Больше всего объявлений однокомнатных квартир, меньше - 5-комнатных.




Гистограммы

Большая часть предложений - от агентств недвижимости




География объявлений


ТОП-10 станций метро по количеству объявлений



ТОП-10 районов Москвы по количеству объявлений



Анализ выбросов



Гипотезы

Чем выше этаж квартиры, тем выше цена за кв. м.

С ростом кол-ва этажей в доме, цена за кв. м. снижается

Квартиры с большим кол-вом комнат имеют более высокую цену за кв. м.

Цена за кв. м. варьируется в зависимости от района расположения квартиры

Цена за кв. м. может изменяться в зависимости от того, принадлежит ли объявление агенту или собственнику

Преобразование переменных

```
# Преобразуем переменную district в числовую категориальную
df['dist_cat'] = pd.Categorical(df['district'])
df['dist_cat'] = df['dist_cat'].cat.codes

# Логарифмируем зависимую переменную price_per_m2
log_price_per_m2 = np.log(df['price_per_m2'])
```

Регрессия

```
# Регрессия
x = df[['floor', 'rooms_count', 'floors_count', 'real_estate_agent_dummy',
        'dist_cat', 'total_meters', 'homeowner_dummy']]

# Создаем модель линейной регрессии
model = sm.OLS(log_price_per_m2, x)
results = model.fit()

# Печатаем статистику модели
print(results.summary())
```

Регрессия

OLS Regression Results

Dep. Variable:	price_per_m2	R-squared (uncentered):	0.923			
Model:	OLS	Adj. R-squared (uncentered):	0.923			
Method:	Least Squares	F-statistic:	8884.			
Date:	Wed, 29 May 2024	Prob (F-statistic):	0.00			
Time:	11:41:44	Log-Likelihood:	-11033.			
No. Observations:	5175	AIC:	2.208e+04			
Df Residuals:	5168	BIC:	2.213e+04			
Df Model:	7					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

floor	-0.0110	0.005	-2.011	0.044	-0.022	-0.000
rooms_count	1.6073	0.036	44.169	0.000	1.536	1.679
floors_count	0.0570	0.004	16.146	0.000	0.050	0.064
real_estate_agent_dummy	1.6377	0.060	27.288	0.000	1.520	1.755
dist_cat	0.0257	0.001	38.454	0.000	0.024	0.027
total_meters	-0.0109	0.001	-13.335	0.000	-0.013	-0.009
homeowner_dummy	1.6956	0.160	10.565	0.000	1.381	2.010
=====						
Omnibus:	86.301	Durbin-Watson:	0.905			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	49.047			
Skew:	-0.006	Prob(JB):	2.24e-11			
Kurtosis:	2.523	Cond. No.	685.			
=====						

Выводы



Чем выше этаж квартиры, тем выше цена за кв. м.



С ростом кол-ва этажей в доме, цена за кв. м. снижается



Квартиры с большим кол-вом комнат имеют более высокую цену за кв. м.



Цена за кв. м. варьируется в зависимости от района расположения квартиры



Цена за кв. м. может изменяться в зависимости от того, принадлежит ли объявление агенту или собственнику

Спасибо за
внимание!



Светлана Камалендинова
Автор